

Classificação Automática de Itens de NF-e em Posições NCM no AgroContábil: comparação entre TF-IDF e BERTimbau

Murillo Weiss Kist, Luiz Felipe Gervazio, Herick Eduardo Vavassori
Engenharia de Software – Centro Universitário Fundação Assis Gurgacz, Toledo - PR

Resumo. Este artigo apresenta um experimento de classificação automática de descrições textuais de itens de Nota Fiscal eletrônica (NF-e) em posições NCM de 4 dígitos, no contexto do AgroContábil, sistema de gestão fiscal para produtores rurais desenvolvido como Trabalho de Conclusão de Curso do grupo. O problema investigado decorre da inexistência de mapeamento determinístico entre descrições livres de produtos e códigos NCM, situação que pode gerar erros de classificação e tributação incorreta. Foi construído um conjunto de dados a partir da API de Dados do Portal da Transparência do Governo Federal, com 1.066 itens finais após limpeza e filtragem para as 50 posições NCM mais frequentes. Foram comparados modelos clássicos baseados em TF-IDF com Logistic Regression e Random Forest, além do BERTimbau base com fine-tuning. Os resultados mostram que os modelos clássicos atingiram acurácia de 0,827 e F1-macro próximo de 0,78, enquanto o BERTimbau obteve 0,640 de acurácia e 0,392 de F1-macro. Discute-se que, no volume atual de dados, o baseline TF-IDF é a alternativa mais adequada.

Palavras-chave: NF-e; NCM; classificação de texto; aprendizado de máquina; AgroContábil; BERTimbau.

Abstract. This paper presents an experiment on automatic classification of textual descriptions of Electronic Invoice (NF-e) items into 4-digit NCM positions, in the context of AgroContábil, a fiscal management system for rural producers developed as the group's undergraduate final project. The investigated problem arises from the absence of a deterministic mapping between free-text product descriptions and NCM codes, which may lead to classification errors and incorrect taxation. A dataset was built from the Brazilian Federal Government Transparency Portal Data API, resulting in 1,066 final items after cleaning and filtering the 50 most frequent NCM positions. Classical TF-IDF-based models with Logistic Regression and Random Forest were compared with BERTimbau base fine-tuning. Results show that the classical models reached 0.827 accuracy and macro-F1 close to 0.78, while BERTimbau reached 0.640 accuracy and 0.392 macro-F1. The discussion indicates that, under the current data volume, the TF-IDF baseline is the most suitable alternative for practical integration.

Keywords: NF-e; NCM; text classification; machine learning; AgroContábil; BERTimbau.

1. Introdução

O AgroContábil é um sistema de gestão fiscal voltado a produtores rurais, desenvolvido como Trabalho de Conclusão de Curso do grupo. Nesse domínio, a emissão, importação e análise de documentos fiscais dependem de informações estruturadas, mas também de campos textuais livres, especialmente nas descrições de itens presentes em Notas Fiscais eletrônicas. Embora a NF-e possua leiautes e esquemas técnicos padronizados pelo Portal Nacional da Nota Fiscal Eletrônica, a descrição do item tende a refletir práticas comerciais, abreviações, nomes de marca, unidades de venda e vocabulário específico do fornecedor.

O problema central deste trabalho é que uma descrição textual de produto não possui mapeamento determinístico para um código da Nomenclatura Comum do Mercosul (NCM). Produtos semanticamente próximos podem pertencer a posições diferentes, enquanto descrições curtas e ambíguas podem ocultar detalhes relevantes sobre composição, processamento ou finalidade de uso. Em um sistema de gestão fiscal, esse problema é crítico porque a classificação incorreta pode conduzir a apuração tributária inadequada, inconsistências em relatórios e necessidade de revisão manual pelo contador ou responsável fiscal.

A motivação torna-se ainda mais relevante no contexto da reforma tributária do consumo no Brasil, instituída pela Emenda Constitucional nº 132/2023 e regulamentada, em parte, pela Lei Complementar nº 214/2025, associada à criação do IBS, da CBS e do Imposto Seletivo. Como o AgroContábil pretende apoiar produtores rurais na organização e análise fiscal, a identificação automática de possíveis pontos críticos em notas fiscais pode reduzir esforço operacional e orientar verificações humanas.

Diante disso, o objetivo deste trabalho é avaliar modelos de aprendizado de máquina para classificar descrições de itens de NF-e em posições NCM de 4 dígitos, comparando baselines clássicos baseados em TF-IDF com um modelo profundo pré-treinado em português brasileiro, o BERTimbau. O estudo busca identificar qual abordagem é mais adequada ao volume de dados atualmente disponível e discutir como a solução pode ser integrada futuramente ao AgroContábil como uma camada de apoio à análise fiscal.

2. Trabalhos Relacionados

Batista, Bagatini e Frozza (2018) desenvolveram um classificador de texto para categorização automática de descrições de itens de produto em códigos NCM utilizando o algoritmo Naïve Bayes. O estudo foi publicado na iSys - Brazilian Journal of Information Systems e utilizou dados de itens de notas fiscais ao consumidor pertencentes aos capítulos 22 e 90 do NCM. Segundo o trabalho, os resultados variaram entre 98% de acurácia no conjunto mais simples e 83% no conjunto mais difícil, o que o torna uma referência direta para a comparação de abordagens de classificação fiscal baseada em texto.

A contribuição desse estudo anterior está em demonstrar que técnicas supervisionadas simples podem capturar padrões relevantes nas descrições fiscais quando há dados rotulados suficientes e escopo controlado. Entretanto, a comparação com o presente trabalho não é direta, pois o dataset aqui utilizado abrange 50 posições NCM de capítulos heterogêneos, com itens ligados ao agronegócio, mas também com forte presença de compras administrativas do Poder Executivo Federal. Ainda assim, o estudo de Batista, Bagatini e Frozza (2018) fornece um baseline histórico importante: verificar se modelos atuais, como BERTimbau, superam ou não técnicas clássicas em um cenário mais amplo e ruidoso.

Além dos trabalhos de classificação fiscal, este estudo se apoia em ferramentas consolidadas de aprendizado de máquina e processamento de linguagem natural. O scikit-learn é utilizado como base para os modelos clássicos e para vetorização TF-IDF, enquanto a biblioteca HuggingFace Transformers viabiliza o fine-tuning do BERTimbau. O BERTimbau, proposto por Souza, Nogueira e Lotufo (2020), é um modelo BERT pré-treinado para português brasileiro e, em princípio, tem capacidade de capturar relações contextuais mais complexas do que representações puramente lexicais.

3. Metodologia

3.1. Fonte e descrição do dataset

O dataset foi construído a partir da API de Dados do Portal da Transparência do Governo Federal, especificamente do conjunto de Notas Fiscais Eletrônicas do Poder Executivo Federal. A estratégia de coleta considerou uma limitação prática do endpoint notas-fiscais: a ausência de filtro por data. Por isso, a coleta foi realizada por órgão, utilizando códigos SIAFI `codigoOrgao` de 5 órgãos ligados ao setor agropecuário, e por nome de produto, utilizando 12 termos do agronegócio: soja, milho, trigo, arroz, fertilizante, adubo, calcário, semente, fungicida, herbicida, ração animal e fertilizante nitrogenado. Ao todo, foram consideradas 17 fontes paginadas.

O detalhamento dos itens, contendo descrição e NCM, foi obtido pelo endpoint notas-fiscais-por-chave. Como a API não oferece filtro por data, registra-se apenas a data de execução da coleta, realizada em 12/06/2026. O conjunto contém notas fiscais de múltiplos exercícios, sem recorte temporal definido. O volume total coletado foi de 1.423 itens brutos, cada um representado por chave `nota`, `descricao_item` e `ncm`. Após a remoção de duplicatas, restaram 1.395 itens. Em seguida, a limpeza removeu linhas com descrição ou NCM nulos e descrições vazias, resultando em 1.365 itens válidos.

No nível de posição NCM, isto é, considerando os 4 primeiros dígitos do código, foram observadas 159 posições distintas. Para tornar o problema experimentalmente viável e reduzir classes com baixíssima frequência, aplicou-se o critério `TOP_N_CLASSES = 50`. O dataset final filtrado contém 1.066 itens, correspondentes a 78,1% do total válido. Nesse conjunto, a menor classe possui 7 exemplos e a maior possui 142 exemplos. As 10 posições NCM mais frequentes foram: 8443 com 142 itens, 1905 com 93, 8471 com 55, 2103 com 53, 2304 com 51, 8504 com 44, 2106 com 39, 0910 com 38, 0713 com 29 e 8708 com 27.

As descrições são curtas e ruidosas, característica típica de itens fiscais. No dataset final, o tamanho médio das descrições foi de 38,4 caracteres, com desvio-padrão de 27,6, mínimo de 3, mediana de 34 e máximo de 120 caracteres. Esse perfil influencia diretamente o desempenho dos modelos, pois há pouco contexto textual disponível para diferenciar produtos semanticamente próximos.

Tabela 1. Síntese do dataset utilizado no experimento

Característica	Valor
Itens brutos coletados	1.423
Itens após remoção de duplicatas	1.395
Itens válidos após limpeza	1.365
Classes NCM em posição de 4 dígitos	159
Critério de filtragem	<code>TOP_N_CLASSES = 50</code>
Itens no dataset final	1.066 (78,1% do total válido)
Menor e maior classe no dataset final	7 e 142 exemplos
Tamanho das descrições	média 38,4; DP 27,6; mínimo 3; mediana 34; máximo 120 caracteres

3.2. Pré-processamento

O pré-processamento iniciou pela remoção de duplicatas exatas considerando a combinação chave `nota`, `descricao_item` e `ncm`. Essa etapa foi necessária porque a coleta foi incremental e retomável, podendo gerar resíduos repetidos. Em seguida, foram removidas linhas com descrição ou NCM nulos e descrições vazias após `strip`.

A normalização do NCM foi uma etapa crítica. A API devolve o campo `codigoNcmSh` sem o zero à esquerda nos capítulos 01 a 09, justamente capítulos importantes para itens agropecuários, como animais, carnes, ovos e laticínios. Para corrigir isso, foram removidos caracteres não numéricos, filtrados códigos com 7 ou 8

dígitos, descartados ruídos como o valor isolado "1", aplicado `zfill(8)` para recompor zeros à esquerda e, por fim, extraídos os 4 primeiros dígitos para formar a label `nem_posicao`. A redução de 8 para 4 dígitos foi adotada como simplificação metodológica, pois o universo completo de códigos NCM de 8 dígitos é muito amplo para o volume de dados disponível.

Após a normalização, o dataset foi filtrado para as 50 posições mais frequentes. Essa escolha preserva a maior parte dos itens válidos e evita a criação de um problema com muitas classes praticamente sem exemplos, o que prejudicaria tanto os modelos clássicos quanto o modelo profundo.

3.3. Modelos comparados

O baseline clássico utilizou TF-IDF com unigramas e bigramas, `min_df=2`, `sublinear_tf` e remoção de acentos. Sobre essa representação textual foram comparados dois classificadores: Logistic Regression e Random Forest. Ambos utilizaram `class_weight` balanceado para mitigar o desbalanceamento entre classes. A divisão treino/teste foi estratificada por classe, com proporção 80/20, resultando em 852 itens de treino e 214 itens de teste, com `random_state=42`.

O modelo profundo avaliado foi o BERTimbau base, identificado como `neuralmind/bert-base-portuguese-cased`, com aproximadamente 110 milhões de parâmetros. Foi realizado fine-tuning para classificação de sequência com a biblioteca HuggingFace Transformers. Os hiperparâmetros utilizados foram `max_len=64`, 5 épocas, batch 16, learning rate $3e-5$, weight decay 0,01 e `seed=42`. O treinamento foi executado em CPU sobre o mesmo split 80/20 utilizado no baseline, garantindo comparação direta entre os modelos.

As métricas de avaliação foram acurácia, F1-macro e matriz de confusão. A acurácia mede a proporção geral de acertos, enquanto o F1-macro calcula a média do F1 por classe atribuindo o mesmo peso a todas as classes. Por isso, em datasets desbalanceados, o F1-macro é particularmente importante para avaliar se o modelo também aprende classes minoritárias.

4. Resultados

A Tabela 2 apresenta a comparação entre os modelos no conjunto de teste, composto por 214 itens e 50 classes. Os dois modelos clássicos empataram em acurácia, com 0,827, e apresentaram F1-macro praticamente equivalente. O Random Forest obteve leve vantagem em F1-macro, com 0,782 contra 0,780 da Logistic Regression. O BERTimbau, por sua vez, ficou claramente abaixo dos baselines, com 0,640 de acurácia e 0,392 de F1-macro.

Tabela 2. Desempenho dos modelos no conjunto de teste

Modelo	Acurácia	F1-macro
Baseline - TF-IDF + Logistic Regression	0,827	0,780
Baseline - TF-IDF + Random Forest	0,827	0,782
BERTimbau (fine-tuning, 5 épocas)	0,640	0,392

A diferença entre acurácia próxima de 0,83 e F1-macro próximo de 0,78 nos modelos clássicos reflete o desbalanceamento de classes. O modelo tende a acertar melhor as classes maiores, enquanto o F1-macro penaliza erros nas classes com poucos exemplos, pois todas as classes recebem o mesmo peso. Ainda assim, considerando 50

classes, descrições muito curtas e apenas 1.066 itens no dataset final, o desempenho do baseline é expressivo.

A evolução do BERTimbau por época sugere subajuste. As métricas de validação cresceram monotonicamente ao longo das 5 épocas: a acurácia evoluiu de 0,39 para 0,50, 0,59, 0,62 e 0,64; o F1-macro evoluiu de 0,08 para 0,19, 0,32, 0,34 e 0,39. Como as métricas ainda subiam na quinta época e a perda de treino permaneceu estabilizada em torno de 1,8, o modelo profundo não chegou a convergir dentro do orçamento de treino disponível.

Na análise da matriz de confusão do melhor baseline, Random Forest, os pares real -> previsto mais confundidos foram 0910 -> 1905, com 2 ocorrências, 2005 -> 0710, com 2 ocorrências, e 8421 -> 8708, também com 2 ocorrências. Também ocorreram confusões isoladas como 0704 -> 2103, 0709 -> 0805, 0709 -> 2106, 0207 -> 0910 e 1102 -> 1104. Esse padrão é coerente com a proximidade semântica e lexical das descrições: posições do capítulo agroalimentar e de preparações compartilham vocabulário e muitas vezes diferem por detalhes de processamento que a descrição curta não explicita.

Entre os acertos observados, o item "Farelo de soja (50 kg) - destinado a alimentação animal" foi classificado corretamente como 2304, assim como os itens "HP W9050MC CARTUCHO DE TONER BLACK 54500 PGS" e "HP W9008MC CARTUCHO DE TONER PRETO 23000 PGS", ambos corretamente classificados como 8443. Entre os erros, "Aveia em flocos finos" foi classificado como 1104, embora o real fosse 1102; "Milho para munguza, pct. com 500g." foi previsto como 1005, enquanto o real era 1104; e "amido, base de mandioca, grupo tapioca, subgrupo goma" foi previsto como 1905, embora o real fosse 1108. Esses exemplos reforçam que termos centrais, como milho, aveia ou tapioca, podem induzir o modelo a uma posição plausível lexicalmente, mas incorreta do ponto de vista fiscal.

5. Discussão

Os resultados indicam que, para o volume atual de dados, o baseline baseado em TF-IDF é a escolha mais recomendada para integração prática ao AgroContábil. Mesmo sendo uma abordagem simples, a combinação de vetorização lexical com classificadores tradicionais atingiu acurácia de 0,827 e F1-macro em torno de 0,78. A equivalência entre Logistic Regression e Random Forest sugere que o sinal preditivo disponível está majoritariamente em termos lexicais discriminativos, como nomes de produtos, marcas e unidades, que o TF-IDF já captura com eficiência.

Os erros restantes concentram-se em pares semanticamente próximos, como grão in natura versus grão processado, especiaria versus produto de padaria ou hortícola preparado versus hortícola congelado. Nesses casos, a decisão fiscal depende de nuances de processamento ou composição que nem sempre aparecem nas descrições. Esse é justamente o tipo de ambiguidade em que se esperaria vantagem de um modelo contextual, mas o experimento mostra que essa vantagem não apareceu com o conjunto atual.

Contrariando a intuição inicial, o BERTimbau ficou abaixo dos baselines clássicos. A causa mais provável não é overfitting, mas subajuste por escassez de dados. O fine-tuning de um modelo de aproximadamente 110 milhões de parâmetros sobre apenas 852 exemplos de treino, distribuídos em 50 classes desbalanceadas, não forneceu sinal suficiente para ajustar a cabeça de classificação e as camadas superiores em poucas épocas. Três evidências sustentam essa leitura: as métricas de validação cresceram

monotonicamente até a última época, a perda de treino permaneceu alta, e o F1-macro ficou muito abaixo da acurácia, indicando dificuldade nas classes minoritárias.

A comparação com Batista, Bagatini e Frozza (2018) também deve ser interpretada com cautela. O baseline deste trabalho, com acurácia de 0,827, fica abaixo dos 0,98 obtidos no conjunto mais simples daquele estudo e próximo dos 0,83 relatados no conjunto mais difícil. Contudo, o presente estudo trabalha com 50 classes heterogêneas, enquanto o trabalho anterior considerou subconjuntos restritos a poucos capítulos do NCM. Portanto, a proximidade com o conjunto mais difícil da literatura sugere que o desempenho alcançado é consistente com a complexidade do cenário avaliado.

Há limitações relevantes. Primeiro, o dataset reflete compras do Poder Executivo Federal, não exclusivamente itens do agronegócio. Mesmo com buscas por produto e órgãos ligados ao setor agropecuário, a posição mais frequente, 8443, refere-se a impressoras e máquinas de impressão, evidenciando a presença de itens administrativos. Segundo, a granularidade foi reduzida para 4 dígitos, pois o NCM completo possui muitos códigos de 8 dígitos para o volume atual de dados. Terceiro, o desbalanceamento é acentuado: no top-50, as classes variam de 7 a 142 exemplos, e 109 posições ficaram fora do dataset final por baixa frequência.

Também é necessário destacar a limitação computacional do experimento com o BERTimbau. O treinamento foi executado em CPU por apenas 5 épocas, e os indícios de subajuste apontam que o modelo profundo não teve seu potencial máximo explorado. Trabalhos futuros podem avaliar mais épocas, ajuste de learning rate, congelamento parcial de camadas, oversampling, focal loss ou outras estratégias para lidar com classes minoritárias. Até que esses experimentos sejam realizados, a recomendação prática permanece a utilização do baseline clássico.

6. Conclusão e Trabalhos Futuros

Este trabalho avaliou a classificação automática de descrições de itens de NF-e em posições NCM de 4 dígitos no contexto do AgroContábil. A partir de dados coletados na API do Portal da Transparência, foi construído um dataset final com 1.066 itens distribuídos nas 50 posições NCM mais frequentes. Foram comparados dois baselines clássicos, TF-IDF com Logistic Regression e TF-IDF com Random Forest, e um modelo profundo, BERTimbau base com fine-tuning.

Os achados indicam que os modelos clássicos são mais adequados ao cenário atual. Ambos alcançaram acurácia de 0,827 e F1-macro próximo de 0,78, enquanto o BERTimbau obteve 0,640 de acurácia e 0,392 de F1-macro. A análise sugere que o volume reduzido de dados, o desbalanceamento e o curto orçamento de treinamento limitaram o desempenho do modelo profundo. Portanto, no estado atual do projeto, recomenda-se integrar inicialmente o baseline TF-IDF como mecanismo de apoio, e não como decisão fiscal automática definitiva.

No AgroContábil, a integração planejada é utilizar o classificador como camada de ponto crítico no relatório do agente fiscal. Em vez de substituir a análise do contador ou do produtor, o modelo pode sinalizar itens cuja descrição e NCM apresentem inconsistência, apresentar uma sugestão de posição NCM e indicar a necessidade de revisão humana. Essa abordagem reduz o risco de automatizar uma decisão tributária sensível e mantém o sistema como ferramenta de apoio à conformidade fiscal.

Como trabalhos futuros, propõe-se expandir o dataset com mais notas e mais diversidade de itens agropecuários, avaliar o NCM em granularidade de 8 dígitos, testar estratégias de balanceamento de classes e retomar o fine-tuning do BERTimbau com

maior orçamento de treino. Também se propõe estender a solução para classificação de CFOP e CST, além de investigar um modelo gerador ou seq2seq para produzir explicações em linguagem natural, permitindo que o relatório do AgroContábil apresente não apenas a sugestão de classificação, mas também uma justificativa compreensível ao usuário.

Referências

- BATISTA, R. A.; BAGATINI, D. D. S.; FROZZA, R. Classificação Automática de Códigos NCM Utilizando o Algoritmo Naïve Bayes. *iSys - Brazilian Journal of Information Systems*, v. 11, n. 2, p. 4-29, 2018.
- BRASIL. Emenda Constitucional nº 132, de 20 de dezembro de 2023. Altera o Sistema Tributário Nacional. *Diário Oficial da União*, Brasília, DF, 2023.
- BRASIL. Lei Complementar nº 214, de 16 de janeiro de 2025. Institui o IBS, a CBS e o Imposto Seletivo, e dá outras providências. *Diário Oficial da União*, Brasília, DF, 2025.
- CONTROLADORIA-GERAL DA UNIÃO. Portal da Transparência do Governo Federal: API de Dados e Notas Fiscais. Brasília, DF, 2026.
- MCKINNEY, W. Data Structures for Statistical Computing in Python. In: *Proceedings of the 9th Python in Science Conference*, 2010. p. 56-61.
- PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.
- PORTAL NACIONAL DA NOTA FISCAL ELETRÔNICA. Documentação, esquemas XML e informações técnicas da NF-e. Brasília, DF, 2026.
- RECEITA FEDERAL DO BRASIL. Nomenclatura Comum do Mercosul (NCM) e documentação fiscal relacionada. Brasília, DF, 2026.
- SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: Pretrained BERT Models for Brazilian Portuguese. In: *Intelligent Systems: 9th Brazilian Conference, BRACIS 2020*. Cham: Springer, 2020. p. 403-417.
- WOLF, T. et al. HuggingFace's Transformers: State-of-the-Art Natural Language Processing. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. 2020. p. 38-45.